

UNIVERSITÀ
DI TORINO

Università degli Studi di Torino

Corso di Laurea Triennale in Informatica

Valutazione dell'età ossea pediatrica da immagini radiografiche con dati articolari

Tesi di Laurea

Relatore
Grangetto Marco

Correlatore
Cannito Michele

Candidato
Deugenio Carlos Michele
992677

Anno Accademico 2025/2026

Dichiarazione di originalità

«Dichiaro di essere responsabile del contenuto dell'elaborato che presento al fine del conseguimento del titolo, di non avere plagiato in tutto o in parte il lavoro prodotto da altri e di aver citato le fonti originali in modo congruente alle normative vigenti in materia di plagio e di diritto d'autore. Sono inoltre consapevole che nel caso la mia dichiarazione risultasse mendace, potrei incorrere nelle sanzioni previste dalla legge e la mia ammissione alla prova finale potrebbe essere negata.»

Indice

1 Introduzione e background **1**

1.1 Il problema della valutazione dell'età ossea 1

1.2 Obiettivo della tesi 1

1.3 Stato dell'arte 2

1.4 Concetti di base di apprendimento profondo 3

1.4.1 Apprendimento supervisionato e regressione 4

1.4.2 Reti neurali a più strati 4

1.4.3 Addestramento 5

1.4.4 Reti neurali convoluzionali 6

1.4.5 Riutilizzo di modelli già addestrati 7

2 Metodo **8**

2.1 Panoramica della pipeline RHPE 8

2.2 Dataset 9

2.2.1 Il dataset RHPE 9

2.2.2 Split del dataset 9

2.2.3 Informazioni usate in ingresso e target 10

2.2.4 Analisi esplorativa 10

2.3 Estrazione delle bounding box e regressione dei punti anatomici 11

2.4 Architettura di BoNet per la regressione dell'età 12

2.4.1 Baseline 12

2.4.2 BoNet 13

2.4.3 Le tre configurazioni confrontate 15

2.5 Addestramento 15

2.5.1 Protocollo del paper e codice ufficiale 15
2.5.2 Impostazioni di questo lavoro 16
2.5.3 Caricamento dei dati e *augmentation* 17
2.5.4 Fase di test 18
2.6 Metriche di valutazione 18

3 Risultati **20**
3.1 Risultati e confronto con il paper originale 20
3.1.1 Valori del paper 20
3.1.2 Valori ottenuti 20
3.1.3 Confronto con il paper originale 22
3.2 Analisi dell'addestramento e delle predizioni 22
3.2.1 Curve di addestramento 22
3.2.2 Predizioni rispetto all'età reale 22

4 Conclusione **25**
4.1 Discussione 25
4.2 Limiti e sviluppi futuri 27

Bibliografia **30**

Capitolo 1

Introduzione e background

1.1 Il problema della valutazione dell'età ossea

L'età ossea è una misura dello sviluppo scheletrico di un bambino [3]. Si distingue dall'età cronologica, perché il grado di maturazione delle ossa varia con il sesso, l'età e l'etnia del paziente, e copre un arco che va da 0 a 20 anni [3]. La valutazione dell'età ossea (*Bone Age Assessment*, BAA) è svolta da radiologi e pediatri per diagnosticare disturbi della crescita o per stimare l'altezza che il bambino raggiungerà da adulto [3, 17]. Si basa sull'ispezione visiva dei pattern di ossificazione in una radiografia della mano e del polso non dominanti [3].

I due metodi manuali più diffusi sono quello di Greulich e Pyle (G&P) [6] e quello di Tanner e Whitehouse (TW2) [17]. Nel metodo G&P la radiografia viene confrontata nel suo insieme con un atlante e assegnata a uno stadio di sviluppo. Nel metodo TW2 la mano è suddivisa in 20 regioni di interesse (*Regions Of Interest*, ROI), analizzate singolarmente per stimare l'età ossea [3]. Poiché analizza localmente la mano, TW2 è più preciso, ma entrambi gli approcci dipendono dall'esperienza del radiologo e dalle variazioni della radiografia, e sono quindi soggetti a errori intra- e inter-osservatore [3]. Questi limiti hanno motivato lo sviluppo di metodi automatici, che puntano a una stima più oggettiva, riproducibile e rapida a partire dalla sola immagine radiografica.

1.2 Obiettivo della tesi

Questa tesi si inserisce in un lavoro più ampio che replica la pipeline proposta da Escobar et al. [3] per la stima automatica dell'età ossea sul dataset RHPE (*Radiological Hand Pose Estimation*). La pipeline ha tre stadi: rilevamento della mano (*hand detection*), stima di 17 punti anatomici (*hand*

pose estimation) e stima dell'età ossea, svolta dal modello BoNet. Questa tesi si occupa dell'ultimo stadio: il modello BoNet, che riceve in ingresso l'immagine ritagliata della mano, una mappa costruita a partire dai punti anatomici (i dati articolari) e il sesso del paziente, e ne regredisce l'età ossea in mesi.

Gli obiettivi sono tre.

1. Replicare l'addestramento di BoNet su RHPE seguendo la descrizione degli autori [3].
2. Confrontare tre configurazioni dell'ingresso: la mappa costruita dai punti anatomici presenti nel dataset RHPE (*Heatmap1*), la mappa costruita dai punti stimati dallo stadio precedente della pipeline [4] (*Heatmap2*) e il modello che non usa alcuna informazione sui punti anatomici (*BoNet*).
3. Confrontare i risultati ottenuti con quelli riportati nel paper originale, discutendo gli scostamenti.

Gli esperimenti usano solo il dataset RHPE.

1.3 Stato dell'arte

Metodi commerciali e approcci classici. Lo strumento automatico più diffuso in ambito clinico è BoneXpert, un software commerciale del 2009 che stima l'età ossea tramite rilevamento dei bordi e *active appearance models*, producendo valutazioni secondo G&P e TW2 [18]. Il metodo è stato sviluppato su una coorte danese, per cui la sua affidabilità su pazienti di altri paesi non è garantita [3]. Questa limitazione motiva la costruzione di dataset su popolazioni diverse, come RHPE.

Dataset disponibili. I dataset pubblici per la BAA forniscono in genere solo l'età ossea a livello di immagine intera, senza indicare le regioni anatomiche rilevanti [3]. Il più usato è quello della RSNA Pediatric Bone Age Challenge del 2017 [7]: contiene 14 236 radiografie pediatriche della mano, ciascuna con l'età ossea in mesi e il sesso del paziente, suddivise in 12 611 immagini di training, 1 425 di validation e 200 di test. Il dataset RHPE, introdotto nel paper originale, ha dimensioni minori (6 288 radiografie) e proviene da una popolazione diversa da quella dei dataset esistenti; oltre all'età ossea fornisce bounding box e punti anatomici, che permettono un'analisi locale della mano. Gli stessi autori hanno annotato bounding box e punti anatomici anche per RSNA [3]. RHPE è descritto in dettaglio nella Sezione 2.2.

Dal deep learning all'informazione locale. I metodi classici come BoneXpert si basano su descrittori progettati a mano. Il deep learning ha cambiato il campo perché le reti neurali convoluzionali apprendono direttamente dalla radiografia le caratteristiche utili alla stima, senza doverle definire a priori, e sfruttano grandi insiemi di immagini come quello della challenge RSNA, che ne ha favorito la diffusione [7]. I metodi sviluppati in questo ambito si possono raggruppare in base a quanta informazione locale usano. Un primo gruppo stima l'età ossea dall'intera immagine: il vincitore della challenge ha ottenuto una distanza assoluta media (*Mean Absolute Distance*, MAD) di 4.26 mesi sul test set, con un ensemble di modelli basati su Inception-V3 e un ramo dedicato al sesso [2, 3], e la maggior parte dei metodi più performanti usava reti poco profonde su tutta l'immagine [3]. Un secondo gruppo introduce un'analisi locale: alcuni metodi estraggono patch sovrapposte o segmentano prima le ossa, ottenendo rispettivamente 4.35 e 4.50 mesi [7], e Iglovikov et al. si concentrano su carpo, metacarpo e falangi prossimali, con 4.97 mesi [11]. Questi approcci sfruttano quindi già informazione locale, ma i dataset esistenti forniscono solo l'età ossea a livello di immagine e non sono pensati per individuare con precisione le regioni anatomiche [3]. Escobar et al. propongono invece di individuare le regioni di interesse tramite la stima della posa della mano, con un'impostazione 2D su radiografie: introducono il dataset RHPE, con bounding box e punti anatomici annotati, e il modello BoNet, che usa questa informazione locale per stimare l'età ossea. Gli autori riportano che BoNet supera i metodi allo stato dell'arte, in particolare un loro baseline che reimplementa la soluzione vincitrice della challenge RSNA [3]. La Tabella 1.1 riassume i valori citati.

Tabella 1.1: Risultati di alcuni metodi di BAA sul test set RSNA, in mesi di MAD, come riportati in [3]. L'ultima riga è BoNet addestrato su RSNA con immagini ritagliate.

Metodo	Fonte	MAD (mesi)
Ensemble Inception-V3 + sesso (vincitore RSNA)	[2]	4.26
Patch sovrapposte	[7]	4.35
Segmentazione delle ossa	[7]	4.50
Carpo, metacarpo, falangi prossimali	[11]	4.97
BoNet (addestramento su RSNA, immagine ritagliata)	[3]	4.14

1.4 Concetti di base di apprendimento profondo

Questa sezione raccoglie gli strumenti di apprendimento profondo che servono a leggere il resto della tesi. Segue le trattazioni di riferimento sul tema [5]. Qui l'attenzione è sul caso della regressione, perché stimare l'età

ossea significa predire un numero e non scegliere una categoria. Dove utile, indico come ciascun concetto compare nel modello usato in questo lavoro.

1.4.1 Apprendimento supervisionato e regressione

In un problema di apprendimento supervisionato si dispone di esempi etichettati, cioè di ingressi a cui è associato il valore che si vuole predire, e si cerca una funzione f_θ, con parametri θ, che approssimi quel valore anche su ingressi mai visti. Se il valore da predire appartiene a un insieme finito di categorie si parla di classificazione; se è un numero reale, come l'età ossea in mesi, di regressione.

Nel caso di questa tesi ogni esempio i ha tre ingressi: la radiografia x_i, il sesso del paziente z_i e la mappa di attenzione r_i, costruita a partire dai punti anatomici. L'uscita è l'età ossea y_i in mesi. La funzione f_θ associa quindi tre ingressi a un'uscita,

$$\hat{y}_i = f_\theta(x_i, z_i, r_i), \tag{1.1}$$

dove $\hat{y}_i$ è l'età predetta. Il modello senza informazione sui punti anatomici non usa r_i e ha la forma $f_\theta(x_i, z_i)$.

Per sapere se il modello funziona su dati nuovi, i dati disponibili si dividono in tre insiemi. Il training set serve a calcolare i parametri; il validation set serve a monitorare l'addestramento e a prendere decisioni come la scelta del punto in cui fermarsi; il test set è riservato alla valutazione finale e non deve influenzare alcuna scelta. Un modello può adattarsi troppo ai dati di addestramento senza generalizzare (*overfitting*), oppure essere troppo semplice per coglierne la struttura (*underfitting*). C'è poi un punto che conta in questo lavoro: un modello apprende una regola valida per il tipo di dati su cui è stato addestrato, e può peggiorare quando i dati di test hanno caratteristiche diverse, per esempio un'inquadratura o una scala differenti.

1.4.2 Reti neurali a più strati

Il modello più semplice per la regressione è lineare, $f(x) = \mathbf{w}^\top x + b$, e può rappresentare solo relazioni lineari fra ingresso e uscita. Una rete neurale aggiunge uno o più *strati nascosti*: ciascuno applica una trasformazione lineare e poi una funzione non lineare, detta funzione di attivazione, a ogni componente,

$$h = \sigma(W_1 x + \mathbf{b}_1), \qquad f(x) = W_2 h + \mathbf{b}_2. \tag{1.2}$$

La non linearità è essenziale: senza di essa la composizione di più strati lineari equivarrebbe a un unico strato lineare. La scelta più diffusa per σ è la ReLU, $\sigma(z) = \max(0, z)$. Accostando molti strati si ottiene una rete profonda; gli strati in cui ogni unità riceve tutte le uscite dello strato precedente si dicono completamente connessi o densi.

Per la regressione l'ultimo strato è lineare, senza attivazione, in modo da poter produrre qualsiasi valore reale. È la struttura della testa di BoNet, descritta nella Sezione 2.4: due strati densi con ReLU seguiti da un'unità di uscita lineare.

1.4.3 Addestramento

Funzione di costo. Addestrare significa scegliere θ in modo da rendere piccola una funzione di costo (*loss*) che misura la distanza fra predizioni e valori veri. Per la regressione due scelte comuni sono l'errore quadratico medio e l'errore assoluto medio (L1),

$$\mathcal{L}_1(\theta) = \frac{1}{N}\sum_{i=1}^{N}\left|f_\theta(x_i, z_i, r_i) - y_i\right|, \tag{1.3}$$

dove N è il numero di esempi su cui la loss è calcolata, $f_\theta(x_i, z_i, r_i) = \hat{y}_i$ è l'uscita del modello per l'esempio i e y_i è il valore vero. L'errore assoluto penalizza ogni scostamento in modo proporzionale, e quindi è meno sensibile ai casi molto sbagliati rispetto a quello quadratico. Ha anche un'interpretazione immediata, perché è espresso nella stessa unità del bersaglio: in questo lavoro, mesi. Per questo motivo coincide con la MAD usata per valutare i metodi di stima dell'età ossea.

Discesa del gradiente e retropropagazione. I parametri si ottimizzano spostandoli, a ogni passo, nella direzione che riduce la loss,

$$\theta_{t+1} = \theta_t - \eta\,\nabla_\theta\mathcal{L}(\theta_t), \tag{1.4}$$

dove θ_t sono i valori dei parametri al passo t; $\nabla_\theta\mathcal{L}(\theta_t)$ è il gradiente della loss, cioè il vettore delle sue derivate parziali rispetto a ciascun parametro, calcolato in θ_t, che indica la direzione in cui la loss cresce più rapidamente; e $\eta > 0$ è il *learning rate*, che stabilisce l'ampiezza del passo. Il segno meno sposta i parametri nella direzione opposta al gradiente, quella in cui la loss diminuisce. Il gradiente rispetto ai parametri di tutti gli strati si calcola in modo efficiente con la retropropagazione dell'errore, che applica la regola di derivazione delle funzioni composte dall'uscita verso l'ingresso [15]. Poiché calcolare il gradiente sull'intero training set a ogni passo sarebbe troppo costoso, lo si stima su piccoli gruppi di campioni, i *mini-batch*; ogni aggiornamento è una iterazione e un passaggio completo sui dati è un'epoca. Il numero di epoche e la dimensione del mini-batch (qui 20) sono iperparametri dell'addestramento.

Momentum, Adam e riduzione del *learning rate*. Il gradiente calcolato su un mini-batch è rumoroso. Il *momentum* lo attenua combinando

il gradiente corrente con quelli dei passi precedenti, tramite una media mobile. Adam spinge oltre questa idea: mantiene due medie mobili, una del gradiente g_t e una del suo quadrato, e adatta il passo di ogni parametro [12],

$$m_t = \beta_1 m_{t-1} + (1-\beta_1) g_t, \quad s_t = \beta_2 s_{t-1} + (1-\beta_2) g_t^2, \quad \theta_{t+1} = \theta_t - \eta \, \frac{\hat{m}_t}{\sqrt{\hat{s}_t} + \varepsilon}, \tag{1.5}$$

dove $g_t = \nabla_\theta \mathcal{L}(\theta_t)$ è il gradiente al passo t; m_t è la media mobile del gradiente e s_t quella del suo quadrato, calcolato componente per componente; $\beta_1, \beta_2 \in [0, 1)$ sono i coefficienti che stabiliscono quanto peso hanno i valori passati; $\hat{m}_t$ e $\hat{s}_t$ sono le stime corrette del bias dovuto all'inizializzazione a zero delle medie; ε è una piccola costante che evita divisioni per zero. Dividere per $\sqrt{\hat{s}_t}$ rende il passo più piccolo per i parametri con gradienti grandi e più grande per quelli con gradienti piccoli. È l'ottimizzatore usato nel paper di BoNet e in questo lavoro. Il *learning rate* può inoltre essere ridotto durante l'addestramento: uno scheduler come `ReduceLROnPlateau` lo moltiplica per un fattore minore di 1 quando la grandezza monitorata smette di migliorare per un certo numero di epoche (la *pazienza*), come descritto nella Sezione 2.5.

Regolarizzazione e normalizzazione. Per contenere l'*overfitting* si ricorre alla *data augmentation*, che genera varianti plausibili dei campioni di training con trasformazioni casuali (rotazioni, traslazioni, cambi di scala, riflessioni), e al controllo sul validation set. Le reti profonde usano spesso la normalizzazione per batch: per ogni canale si sottrae la media del mini-batch e si divide per la sua deviazione standard, poi si applica una scala e uno spostamento appresi,

$$\hat{a} = \frac{a - \mu_B}{\sqrt{\sigma_B^2 + \varepsilon}}, \qquad \tilde{a} = \gamma \, \hat{a} + \beta, \tag{1.6}$$

dove a è il valore di un'attivazione, cioè l'uscita di un'unità dello strato precedente per un campione del mini-batch; μ_B e σ_B^2 sono la media e la varianza di quell'attivazione sul mini-batch B; ε è una piccola costante che evita divisioni per zero; $\hat{a}$ è l'attivazione normalizzata, con media circa zero e varianza circa uno; γ e β sono parametri appresi durante l'addestramento, che permettono alla rete di ristabilire scala e posizione più utili; $\tilde{a}$ è il valore passato allo strato successivo. In fase di valutazione si usano al posto di μ_B e σ_B^2 le statistiche accumulate durante l'addestramento, per cui il comportamento della rete in training e in valutazione è diverso.

1.4.4 Reti neurali convoluzionali

Quando l'ingresso è un'immagine, appiattirla in un vettore per darla a uno strato denso ne distrugge la struttura spaziale e richiede moltissimi

parametri. Uno strato convoluzionale fa scorrere sull'immagine piccoli filtri, con gli stessi pesi in ogni posizione, e calcola in ciascuna un prodotto scalare fra il filtro e la porzione di immagine sottostante,

$$(I * K)(i, j) = \sum_{a} \sum_{b} K(a, b)\, I(i + a,\, j + b), \tag{1.7}$$

dove I è l'immagine (o la mappa di feature) in ingresso, K è il filtro, una piccola matrice di pesi appresi, (i, j) è la posizione nella mappa di uscita, e a, b percorrono le righe e le colonne del filtro. Il valore in (i, j) è quindi la somma dei prodotti fra ciascun peso del filtro e il pixel corrispondente della porzione di immagine che il filtro ricopre in quel punto. Ne risultano mappe di feature che rilevano pattern locali (bordi, texture) indipendentemente dalla loro posizione. Il passo del filtro (*stride*) e il riempimento ai bordi (*padding*) determinano le dimensioni della mappa, e operazioni di *pooling* la riducono ulteriormente. Impilando strati convoluzionali la rete costruisce rappresentazioni sempre più astratte, dai bordi alle forme complesse.

Nelle architetture usate qui l'unità di base è un blocco formato da convoluzione, normalizzazione per batch e ReLU. Inception-V3 [16] organizza questi blocchi in moduli con più rami paralleli, che applicano filtri di dimensioni diverse alla stessa mappa e ne concatenano le uscite. In questo modo il modello esamina contemporaneamente strutture a scale diverse. Dopo l'ultimo modulo, una media globale sulle posizioni spaziali riduce la mappa a un vettore di feature, che alimenta la testa di regressione. Questa è la parte convoluzionale di BoNet e del baseline (Sezione 2.4).

1.4.5 Riutilizzo di modelli già addestrati

Addestrare una rete profonda da zero richiede molti dati e tempo. Una pratica diffusa è partire dai pesi di una rete già addestrata su un altro compito o su un'altra base dati, per sfruttare le rappresentazioni già apprese, specie quelle degli strati iniziali, che tendono a essere generali. Si distinguono due strategie: lasciare fissi i pesi riutilizzati e addestrare solo i nuovi strati finali (*feature extraction*), oppure continuare ad aggiornare anche i pesi di partenza sul nuovo compito (*fine-tuning*).

Capitolo 2

Metodo

2.1 Panoramica della pipeline RHPE

La pipeline di Escobar et al. [3] imita il modo di procedere dei radiologi, che valutano regioni anatomiche specifiche della mano. Ha tre stadi (Figura 2.1).

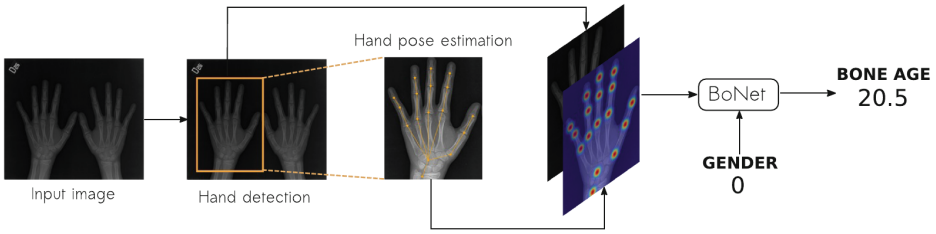


Figura 2.1: Schema della pipeline RHPE, tratto da [3]: la radiografia originale passa per la *hand detection* e la *hand pose estimation*, e BoNet riceve in ingresso l'immagine croppata, la mappa di attenzione e il sesso (*gender*) per stimare l'età ossea (*bone age*).

I tre stadi sono:

1. **Hand detection:** la radiografia originale contiene due mani; una bounding box permette di ritagliare solo la mano sinistra, che è quella su cui viene valutata l'età ossea anche nel flusso di lavoro clinico.
2. **Hand pose estimation:** stima la posizione di 17 punti anatomici all'interno del ritaglio della mano.
3. **Bone age assessment:** il modello BoNet riceve la radiografia della mano sinistra croppata, una mappa di attenzione costruita sui punti anatomici e il sesso del paziente, e produce l'età ossea.

I primi due stadi sono descritti nella Sezione 2.3; il terzo, oggetto di questa tesi, nelle Sezioni 2.4 e 2.5.

2.2 Dataset

2.2.1 Il dataset RHPE

RHPE è composto da 6 288 radiografie di mani sinistre e destre di pazienti pediatrici di sesso maschile e femminile, tra 0 e 240 mesi di età (0–20 anni), raccolte presso la Fundación Santa Fe de Bogotá (Colombia) [3]. Per ogni paziente l'età ossea è stata annotata da due radiologi esperti. Il dataset fornisce inoltre le bounding box della mano e 17 punti anatomici, annotati da 96 soggetti addestrati: dopo aver scartato gli outlier, ogni immagine ha almeno 4 annotazioni indipendenti, per oltre 1.3 milioni di punti complessivi [3]. Le annotazioni sono salvate nel formato MS-COCO [13]. Secondo gli autori la distribuzione dell'età ossea è circa gaussiana, centrata attorno a 126 mesi, con il 54% di pazienti femmine e il 46% maschi [3].

Ogni immagine mostra entrambe le mani, ma bounding box e punti anatomici riguardano solo la mano sinistra. Il paper indica che per la valutazione bisogna isolare la mano non dominante e che, poiché la maggior parte delle persone è destrimane, si assume statisticamente che la mano sinistra sia quella non dominante [8, 3].

2.2.2 Split del dataset

Il dataset è diviso in 5 492 immagini di training, 716 di validation e 80 di test [3]. La versione di RHPE utilizzata in questo lavoro contiene 5 491 immagini di training, 713 di validation e 79 di test (Tabella 2.1), gli stessi conteggi di [4]. Dai file CSV risulta che gli intervalli di ID sono 1–5496, 5497–6212 e 6213–6292 e che ne mancano rispettivamente 5 (1289, 4215, 4977, 5280, 5294), 3 (5568, 5762, 6188) e 1 (6274). Rispetto ai conteggi del paper i file contengono quindi 1, 3 e 1 immagini in meno nei tre split; non è documentato il motivo.

Tabella 2.1: Composizione per split e per sesso della versione di RHPE usata in questo lavoro, calcolata dai file CSV; i valori coincidono con quelli di [4].

Split	Immagini	Maschi	Femmine
Training	5 491	2 372 (43.2%)	3 119 (56.8%)
Validation	713	306 (42.9%)	407 (57.1%)
Test	79	38 (48.1%)	41 (51.9%)

2.2.3 Informazioni usate in ingresso e target

Ogni campione è descritto da: l'immagine radiografica, le annotazioni in formato JSON (bounding box e 17 punti) e un file CSV con età ossea, età cronologica e sesso [4]. BoNet usa in ingresso il ritaglio della mano, la mappa di attenzione e il sesso, e ha come target l'età ossea in mesi [3]. Nei set di training e di validation sono disponibili sia l'età ossea sia l'età cronologica; il set di test contiene solo la cronologica. L'addestramento e la validazione leggono le annotazioni da `RHPE_Boneage_train.csv` e `RHPE_Boneage_val.csv`, e il target è l'età ossea.

Il test set di RHPE non include l'età ossea, che deve essere predetta: gli autori mettono a disposizione un server di valutazione [3, 4]. Nel test in nostro possesso (file `RHPE_Gender_Chronological_test.csv`, che contiene solo sesso ed età cronologica) la grandezza di riferimento è quindi l'*età cronologica* in mesi, e su questa sono calcolate le metriche di test del Capitolo 3. Nei 79 pazienti l'età cronologica va da 29 a 201 mesi (media 123.1, mediana 125, deviazione standard 39.3).

2.2.4 Analisi esplorativa

Le statistiche seguenti sono calcolate direttamente dai file CSV dei tre split (Tabella 2.2, Figure 2.2, 2.3 e 2.4).

Tabella 2.2: Statistiche descrittive di età ossea ed età cronologica (mesi) per split: media (deviazione standard) e intervallo.

Split	Età ossea	Età cronologica
Training	123.0 (41.5), 12–228	124.2 (38.8), 10–242
Validation	122.9 (41.5), 12–228	123.6 (38.8), 11–265
Test	non disponibile	123.1 (39.3), 29–201

Training e validation hanno distribuzioni molto simili, sia per età ossea sia per età cronologica; quella del test, con soli 79 pazienti, è più irregolare (Figura 2.2). Il sesso influisce sul rapporto fra le due età: nei maschi l'età ossea è in media inferiore alla cronologica (di 4.4 mesi in training e 4.7 in validation), nelle femmine superiore (di 1.4 e 2.3 mesi).

Le due età sono fortemente correlate (coefficiente di correlazione 0.950 in training e 0.946 in validation), ma non coincidono: la differenza media (ossea meno cronologica) è −1.11 mesi in training e −0.71 in validation, l'errore assoluto medio fra le due età (MAD) è di 10.0 e 10.5 mesi, e per il 29.8% e il 31.8% dei pazienti la differenza supera i 12 mesi (Figura 2.4). Ne segue un punto utile per leggere i risultati: una rete che prevedesse esattamente l'età ossea avrebbe una L1 di circa 10 mesi se valutata rispetto all'età cronologica.

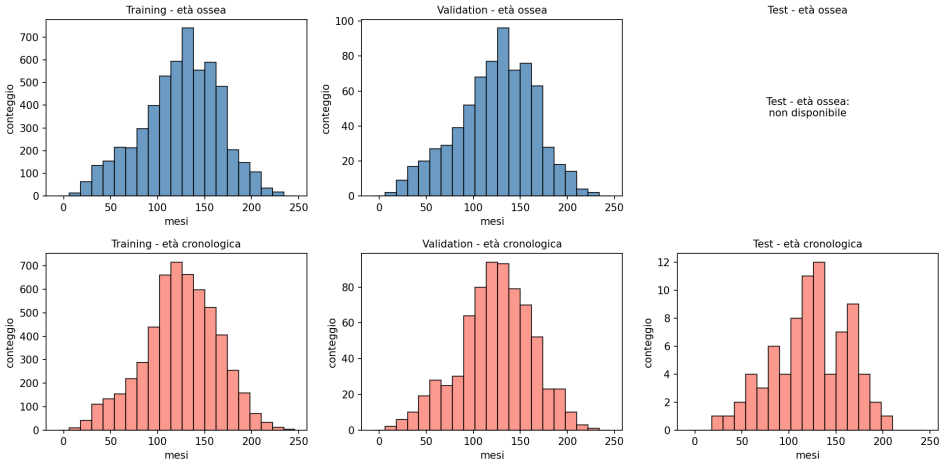


Figura 2.2: Distribuzione di età ossea ed età cronologica nei tre split di RHPE.

Il valore è misurato su training e validation, perché nel test l'età ossea non è disponibile.

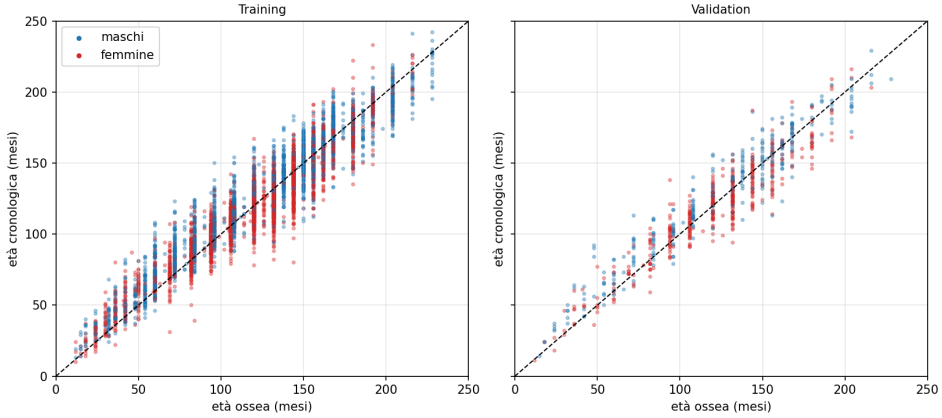


Figura 2.3: Età cronologica in funzione dell'età ossea in training e validation (maschi in blu, femmine in rosso); la linea tratteggiata è $y = x$.

2.3 Estrazione delle bounding box e regressione dei punti anatomici

I primi due stadi della pipeline sono stati sviluppati da Giacomelli [4]; qui ne richiamo solo gli aspetti necessari a capire gli ingressi di BoNet.

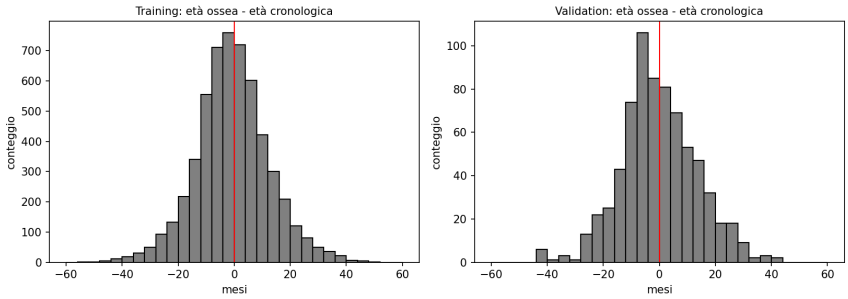


Figura 2.4: Distribuzione della differenza fra età ossea ed età cronologica in training e validation.

Hand detection. Il rilevamento della mano usa Faster R-CNN [14] con backbone ResNet-50 [10] e *Feature Pyramid Network*, adattato a RHPE con *fine-tuning*; sul validation set raggiunge una mAP@[.5:.95] di 0.8856, confrontabile con il 90.1% riportato dal paper pur essendo addestrato su soli 250 campioni [4].

Stima dei punti anatomici. I 17 punti sono tre per ciascun dito, più due punti di ancoraggio [4]. Il paper originale usa Simple Baselines [19]; il lavoro di Giacomelli usa invece Keypoint R-CNN [9], e la valutazione usa la similarità fra punti OKS (*Object Keypoint Similarity*) del benchmark COCO [13]. I punti usati in fase di test per costruire la mappa di *Heatmap2* provengono dal modello `gt_crop` riallenato sull'intero training set con *data augmentation* (rotazione e scala casuali, applicate al 35% dei campioni), usato in modalità `det_crop`, cioè su ritagli ottenuti dalle bounding box predette dal modello di detection [4]. Di questa pipeline si usano solo le coordinate dei punti; le bounding box predette non sono usate per il ritaglio. Su test set questa configurazione raggiunge una mAP@[.5:.95] di 0.7668 [4]; il paper riporta 0.808 con bounding box predetta, valore che lo stesso lavoro invita a trattare con cautela, perché la tabella originale riporta risultati identici per i due dataset di riferimento in due condizioni su tre [4, 3].

2.4 Architettura di BoNet per la regressione dell'età

2.4.1 Baseline

Il baseline degli autori reimplementa la soluzione vincitrice della challenge RSNA [2]. Usa un'architettura Inception-V3 [16] combinata con una rete che incorpora l'informazione sul sesso e due strati densi da 1 000 neu-

roni che producono la stima finale. A differenza della soluzione originale, in inferenza usa un solo modello anziché un ensemble [3]. Nel codice ufficiale [1] il corpo di Inception-V3 è adattato a immagini in scala di grigi, con un solo canale in ingresso (per i concetti di base sulle reti convoluzionali si veda la Sezione 1.4.4).

2.4.2 BoNet

BoNet parte dall'idea di imitare il modo di lavorare dei medici, che guardano regioni anatomiche precise della mano. La rete riceve in ingresso la radiografia ritagliata e una mappa di attenzione, costruita generando una distribuzione gaussiana attorno a ciascun punto anatomico [3]. Seguendo il suggerimento della soluzione vincitrice di RSNA [2], viene aggiunta l'informazione sul sesso, e gli strati finali regredicono l'età ossea con una loss L1 [3].

Nel codice ufficiale [1] l'architettura è la seguente (Figura 2.5). L'ingresso è un tensore a due canali di 500×500 pixel: la radiografia e la mappa di attenzione. I due canali attraversano due percorsi indipendenti, ciascuno formato dai primi cinque blocchi convoluzionali di Inception-V3 [16] con due *max-pooling*, che producono 192 canali per percorso. Le due uscite sono concatenate (384 canali) e ridotte a 192 canali da una convoluzione 1×1; il risultato attraversa il corpo di Inception-V3, cioè i moduli Inception `Mixed_5b`–`Mixed_7c`, e un *average pooling*, che dà $2048 \times 7 \times 7 = 100\,352$ feature. Il sesso passa da uno strato denso con 32 unità e ReLU; le 32 feature sono concatenate alle 100 352 dell'immagine e passano per tre strati densi ($100\,384 \to 1000$ e $1000 \to 1000$, entrambi con ReLU, e $1000 \to 1$) che producono l'età ossea. Il primo strato denso ha oltre 100 milioni di parametri. I pesi di convoluzioni e strati densi sono inizializzati con una distribuzione normale troncata di deviazione standard 0.1.

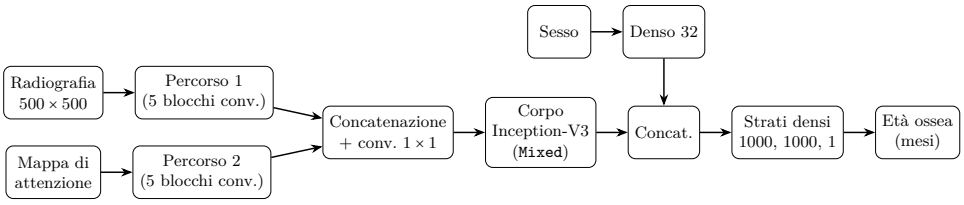


Figura 2.5: Architettura di BoNet nel codice ufficiale [1], con le dimensioni dell'ingresso a 500×500 pixel. Il percorso 2 riceve la mappa di attenzione.

Nel codice ufficiale [1] la mappa di attenzione è costruita così: su un'immagine nulla, in ciascuno dei 17 punti anatomici si pone una finestra di 3×3 pixel di valore circa 255; l'immagine è poi sfocata con un filtro gaussiano di

deviazione standard $\sigma = 25$ pixel,

$$H = G_\sigma * P, \quad P(x,y) \approx \begin{cases} 255 & \text{se } (x,y) \text{ è nella finestra di un punto,} \\ 0 & \text{altrimenti.} \end{cases} \tag{2.1}$$

Per un punto isolato l'ampiezza risultante è molto bassa: circa 0.58 sulla scala in cui la radiografia va da 0 a 255, e circa 1 dove i punti sono vicini (valori ricavati numericamente dalla procedura del codice).

In questo lavoro le mappe sono precalcolate con uno script che segue la stessa procedura, con tre differenze: le finestre di punti vicini sono combinate con il massimo anziché sovrascritte; i punti vicini al bordo dell'immagine sono gestiti senza errori; ogni mappa è riscalata in modo che il suo massimo valga 255 e poi salvata come immagine a 8 bit (un file `*_h.png` per radiografia), per evitare mappe nulle:

$$\tilde{H} = 255 \, \frac{G_\sigma * P}{\max (G_\sigma * P)}. \tag{2.2}$$

La mappa ha le stesse dimensioni della radiografia intera ed è ritagliata insieme a essa dal caricatore dei dati. Per *Heatmap2* le mappe del test sono rigenerate con lo stesso script a partire dai punti stimati da Giacomelli; lo script elimina le mappe esistenti nella cartella e le ricrea. Le mappe di training e di validation sono state generate con la stessa procedura, riscalatura compresa. La Figura 2.6 mostra un esempio per una radiografia di RHPE: la mappa contiene 17 punti luminosi, uno per ciascun punto anatomico della mano sinistra, ed è nulla altrove.



(a) (b) (c)

Figura 2.6: Esempio di ingresso di BoNet con mappa di attenzione: (a) radiografia con entrambe le mani; (b) mappa di attenzione, con una gaussiana per ciascuno dei 17 punti anatomici della mano sinistra; (c) sovrapposizione della mappa alla radiografia.

La loss è la media dell'errore assoluto tra età predetta $\hat{y}_i$ ed età di riferimento y_i su N campioni,

$$\mathcal{L}_1 = \frac{1}{N} \sum_{i=1}^{N} |\hat{y}_i - y_i|, \tag{2.3}$$

che coincide numericamente con la MAD usata dal paper come metrica di valutazione [3].

2.4.3 Le tre configurazioni confrontate

Il confronto di questa tesi riguarda tre configurazioni, che differiscono per l'origine dell'informazione sui punti anatomici (Tabella 2.3).

Tabella 2.3: Configurazioni confrontate. Le denominazioni sono quelle usate nei risultati sperimentali.

Configurazione	Ingresso
Heatmap2	Stesso modello di *Heatmap1*; in test la mappa di attenzione è costruita con i punti stimati dallo stadio precedente della pipeline [4], mentre il ritaglio resta quello della bounding box di RHPE
Heatmap1	Mappa di attenzione costruita con i valori dei punti presenti nel dataset RHPE (in training e in test) [3]
BoNet	Dataset RHPE, senza alcuna informazione sui punti anatomici

Heatmap1 e *Heatmap2* sono lo stesso modello, con un'unica architettura e un unico addestramento svolto sui punti annotati in RHPE: si distinguono solo in fase di test, in cui la mappa di attenzione è costruita con i punti di RHPE (*Heatmap1*) oppure con quelli stimati da Giacomelli (*Heatmap2*). *BoNet* non ha il percorso della mappa; come le altre due configurazioni, riceve l'immagine e il sesso. Corrisponde al modello eseguito senza l'opzione `--heatmaps`, cioè, per tipo di ingresso, al baseline del paper: un corpo Inception-V3 a un solo canale con la stessa testa del modello con mappa (sesso con strato denso a 32 unità e strati $100\,384 \to 1000 \to 1000 \to 1$), mentre il modello con mappa corrisponde a BoNet.

2.5 Addestramento

2.5.1 Protocollo del paper e codice ufficiale

Le nozioni di base su loss, ottimizzatori e scheduler sono nella Sezione 1.4.3. Nel paper originale BoNet viene addestrato partendo dai pesi del baseline, con l'ottimizzatore Adam [12], *learning rate* iniziale 10^{-4} per 50 epoche e riduzione del *learning rate* di un fattore 0.1 quando la loss raggiunge un plateau. Il baseline, a sua volta, è addestrato per 150 epoche con Adam e *learning rate* iniziale 3×10^{-3} [3].

Lo script di addestramento del codice ufficiale [1] minimizza una loss L1 con Adam e usa lo scheduler `ReduceLROnPlateau` con fattore 0.8 (non 0.1, come invece indicato nel testo del paper), pazienza configurabile, *cooldown* di 5 epoche e *learning rate* minimo 10^{-5}; lo scheduler è aggiornato sulla loss di training. Le immagini sono ridimensionate a 500×500 pixel e, in training, sottoposte a *data augmentation* con rotazione fino a 20°, traslazione fino al 20%, scala tra 1 e 1.2 e riflessione orizzontale. L'addestramento è distribuito con Horovod: il *learning rate* è moltiplicato per il numero di processi e la *batch size* effettiva cresce con il numero di GPU. Il valore predefinito dello script indica due GPU. Il checkpoint con la migliore loss di validation è salvato con una condizione che, nel codice ufficiale, risulta invertita (si salva quando la loss peggiora).

2.5.2 Impostazioni di questo lavoro

Il codice ufficiale usa Horovod per distribuire l'addestramento su più GPU; per questo lavoro Horovod è stato rimosso e addestramento, validazione e test sono stati eseguiti su una sola GPU NVIDIA 3060. La versione dello script è quindi a GPU singola, con *learning rate* 10^{-4} non scalato e *batch size* 20 (4 processi di caricamento dati). L'addestramento va dall'epoca 0 alla 60 (61 epoche effettive), con pazienza 2, *seed* 1111 e mescolamento casuale degli esempi. Rispetto al codice ufficiale, lo script ha anche queste modifiche: la condizione di salvataggio del miglior modello è corretta (si salva quando la loss di validation diminuisce); il caricamento dei pesi del baseline copia i parametri delle prime cinque convoluzioni Inception in entrambi i percorsi di BoNet e quelli con nome e forma identici, lasciando gli altri con l'inizializzazione casuale.

I pesi del baseline di partenza non sono forniti dagli autori e sono stati addestrati in questo lavoro con gli stessi iperparametri (60 epoche, *learning rate* 10^{-4}), quindi con un protocollo diverso da quello del paper. Il comando di addestramento riportato ha l'opzione `--heatmaps` commentata, e corrisponde quindi all'esecuzione senza mappa di attenzione; il modello con mappa è addestrato con lo stesso comando e l'opzione `--heatmaps` attiva. Rispetto al comando riportato non è stato cambiato altro. Non passa invece un file di pesi: per il modello con mappa i pesi iniziali sono letti, se presenti, dal file predefinito `boneage_bonet_weights.pth` della cartella dell'esperimento. Il baseline, a sua volta, è addestrato a partire da pesi casuali: non si usano pesi pre-addestrati su ImageNet, che del resto non potrebbero essere caricati direttamente perché il suo primo strato convoluzionale ha un solo canale.

Prima dell'addestramento la rete viene valutata una volta sul validation set (`--eval-first`); questo valore non fa parte delle 61 epoche registrate. Il

seed è quello predefinito (1111). Per ogni epoca sono registrate due loss L1 in mesi, di training e di eval, definite nella Sezione 2.6.

2.5.3 Caricamento dei dati e *augmentation*

Le immagini sono lette in scala di grigi. Ogni radiografia di RHPE contiene due mani, quindi prima del modello va selezionata la mano sinistra. Il codice prevede due modalità. Con l'opzione `--cropped` la radiografia è ritagliata con la bounding box della mano, dal file JSON. Senza questa opzione, per RHPE, si usa la metà sinistra della radiografia (le prime metà delle colonne, per tutta l'altezza), che contiene la mano sinistra insieme a una parte di sfondo; è la modalità che il paper chiama «immagine intera» (*full image*), definita per RHPE proprio come la metà sinistra della radiografia, per includere solo la mano non dominante [3]. Il ritaglio, in entrambe le modalità, è poi ridimensionato a 500×500 pixel con `Resize((500, 500))`, che porta l'immagine a un quadrato senza preservare il rapporto d'aspetto: la mano risulta deformata, in modo diverso a seconda dell'inquadratura (metà sinistra o bounding box). Il sesso e il target sono letti dal file CSV: il sesso dalla seconda colonna e il target dalla terza, che è `Boneage` in training e validation e `Chronological` nel test. Per il modello con mappa il campione è un tensore a due canali (radiografia e mappa). Radiografia e mappa precalcolata hanno le stesse dimensioni originali (il caricatore lo verifica) e subiscono lo stesso ritaglio e lo stesso ridimensionamento. I punti anatomici non sono quindi riscalati separatamente: sono contenuti nella mappa, e la deformazione dovuta al ridimensionamento è la stessa per i due canali.

Rispetto al caricamento dati del codice ufficiale [1], che calcola la mappa al volo dai punti del JSON, la versione di questo lavoro legge le mappe precalcolate e converte entrambi i canali a 8 bit, per cui la conversione a tensore li riporta fra 0 e 1. Nel codice ufficiale, invece, la radiografia resta nella scala 0–255 e la mappa nella scala 0–1 circa, perché le immagini float non vengono riscalate dalla conversione.

Il comando di addestramento non passa l'opzione `--cropped`: per RHPE, training e validation usano quindi la metà sinistra della radiografia, mentre il test, eseguito con `--cropped`, usa il ritaglio con la bounding box della mano. Si tratta di una conseguenza dell'assenza dell'opzione nel comando e non di una scelta sperimentale; il paper ottiene i suoi migliori risultati addestrando e testando sui ritagli [3]. Nel codice ufficiale la metà sinistra è calcolata con altezza e larghezza scambiate, per cui su immagini non quadrate il taglio non cade a metà larghezza; nel caricamento dei dati di questo lavoro l'errore è corretto.

2.5.4 Fase di test

In fase di test lo script del codice ufficiale viene eseguito su una GPU con *batch size* 1. Carica il file `boneage_bonet_snapshot.pth`, che viene sovrascritto a ogni epoca e contiene quindi i pesi dell'ultima epoca (la 60), non quelli del checkpoint con la minima loss di eval. Usa sempre l'opzione di ritaglio della mano (`--cropped`) e, per i modelli con mappa di attenzione, l'opzione `--heatmap`. Bounding box e punti anatomici sono letti da un file JSON delle ROI. Ciò che distingue *Heatmap1* da *Heatmap2* sono solo le coordinate dei punti, che per *Heatmap2* sono sostituite con quelle stimate da Giacomelli; le bounding box usate per il ritaglio restano quelle annotate in RHPE.

La Tabella 2.4 confronta le impostazioni.

Tabella 2.4: Impostazioni di addestramento: paper originale [3], codice ufficiale [1] e questo lavoro.

	Paper originale	Codice ufficiale	Questo lavoro
Loss	L1	L1	L1
Ottimizzatore	Adam	Adam	Adam
Learning rate iniziale	10^{-4}	10^{-5} predefinito, moltiplicato per i processi	10^{-4}, non scalato
Scheduler	×0.1 al plateau	×0.8, *cooldown* 5, minimo 10^{-5}	×0.8, pazienza 2, *cooldown* 5, minimo 10^{-5}
Epoche	50	20 predefinite	60 (da 0 a 60)
Inizializzazione	pesi del baseline	pesi di uno snapshot	pesi del baseline (addestrati qui da pesi casuali)
Batch size (training)	non indicata	1 predefinita, per GPU	20
Batch size (eval e test)	non indicata	1	1
GPU	non indicata	Horovod, 2 predefinite	1 (NVIDIA 3060), senza Horovod
Risoluzione ingresso	non indicata	500×500	500×500
Augmentation (training)	non indicata	rotazione, traslazione, scala, flip	come il codice ufficiale
Immagine ritagliata	sì (configurazione migliore)	opzione `--cropped`	training e validation: no (metà sinistra); test: sì

2.6 Metriche di valutazione

Loss di addestramento. La loss è la funzione che il modello minimizza durante l'addestramento. In questo lavoro è l'errore assoluto medio (L1) fra l'età predetta $\hat{y}_i = f_\theta(x_i, z_i, r_i)$ e il valore di riferimento y_i, in mesi. Su un

mini-batch B di $|B|$ campioni vale

$$\mathcal{L}_1(B) = \frac{1}{|B|} \sum_{i \in B} |\hat{y}_i - y_i|, \tag{2.4}$$

e i parametri sono aggiornati con il gradiente di questa quantità. In training e in validation il riferimento y_i è l'età ossea. Per ogni epoca si registrano due valori: la *loss di training*, media delle loss dei mini-batch calcolate durante l'epoca (con *augmentation* e con pesi che cambiano man mano), e la *loss di eval*, media sull'intero validation set calcolata a fine epoca con pesi fissi, senza *augmentation* e con *batch size* 1. Le due curve servono a descrivere la convergenza e non sono confrontabili in valore assoluto.

Metrica di valutazione: MAD. La metrica con cui si valuta un modello su un insieme di N campioni è la distanza assoluta media (*Mean Absolute Distance*, MAD), detta anche errore assoluto medio (MAE), usata dal paper originale [3]:

$$\text{MAD} = \frac{1}{N} \sum_{i=1}^{N} |\hat{y}_i - y_i|. \tag{2.5}$$

Numericamente coincide con la L1, ma i due ruoli sono distinti: la L1 è la funzione di costo ottimizzata durante l'addestramento, la MAD è la misura della qualità del modello, espressa in mesi, e va resa la più piccola possibile. La loss di eval è la MAD sul validation set, rispetto all'età ossea.

MAD di test. Nel test set di RHPE è disponibile solo l'età cronologica (Sezione 2.2), per cui la MAD di test è calcolata sui 79 pazienti rispetto all'età cronologica. Non è quindi confrontabile con la MAD del paper, che usa l'età ossea stimata dai radiologi, ottenuta con il server di valutazione degli autori.

Intervalli di confidenza. Per quantificare l'incertezza dovuta alla piccola dimensione del test set, gli intervalli di confidenza al 95% sono stati calcolati con un *bootstrap* percentile (20 000 ricampionamenti dei 79 pazienti); le differenze fra configurazioni sono calcolate sugli stessi pazienti (differenza appaiata).

Capitolo 3

Risultati

Le metriche usate (loss di training e di eval, MAD di test e intervalli di confidenza bootstrap) sono definite nella Sezione 2.6.

3.1 Risultati e confronto con il paper originale

3.1.1 Valori del paper

La Tabella 3.1 riporta i risultati di BoNet e del baseline sul test set RHPE quando l'addestramento usa solo RHPE, come valutati con il server degli autori [3]. Training e validation di questo lavoro usano la metà sinistra della radiografia, che per RHPE è la condizione «immagine intera» del paper (Sezione 2.5.3): per la loss di eval le righe di riferimento sono quindi quelle a immagine intera, in grassetto in tabella. Il test è invece eseguito sul ritaglio della mano con la bounding box.

Tabella 3.1: MAD (mesi) sul test set RHPE per modelli addestrati su RHPE [3].

Modello	MAD
Baseline (immagine intera)	**8.57**
BoNet (immagine intera)	**7.78**
Baseline + immagine ritagliata	8.05
BoNet + immagine ritagliata	7.60

3.1.2 Valori ottenuti

La Tabella 3.2 riassume le curve di addestramento e la Tabella 3.3 i risultati finali sul test set.

Tabella 3.2: Loss L1 per epoca (61 valori), di training e di valutazione (Eval). La riduzione è calcolata rispetto al valore iniziale. «Heatmap» indica il modello con la mappa di attenzione, addestrato una sola volta e quindi comune a *Heatmap1* e *Heatmap2*.

Modello	Loss	Iniziale	Finale	Minimo	Epoca min.	Riduzione
Heatmap	Training	38.678	15.711	15.711	60	59.4%
Heatmap	Eval	31.231	15.428	14.775	59	50.6%
BoNet	Training	33.397	8.540	8.520	58	74.4%
BoNet	Eval	28.595	9.517	8.880	50	66.7%

Tabella 3.3: MAD sul test set (79 pazienti, mesi), calcolata rispetto all'età cronologica, con intervallo di confidenza bootstrap al 95%. Le variazioni percentuali sono rispetto a *Heatmap2*; la differenza appaiata è la media delle differenze degli errori assoluti per paziente.

Configurazione	MAD test	IC 95%	Variazione	Differenza appaiata (IC 95%)
Heatmap2	17.42059	[14.25; 20.81]	riferimento	—
Heatmap1	17.54413	[14.31; 20.95]	+0.71%	+0.12 [−0.23; +0.48]
BoNet	15.25022	[12.84; 17.78]	−12.46%	−2.17 [−6.87; +2.46]

Rispetto a *Heatmap1*, *BoNet* riduce la MAD del 13.07% (−2.29 mesi in media, IC 95% [−6.99; +2.37]). Gli intervalli di confidenza delle tre configurazioni si sovrappongono ampiamente e le differenze appaiate di *BoNet* includono lo zero: con 79 pazienti il test non separa in modo netto le tre configurazioni. Le due configurazioni con mappa di attenzione sono invece praticamente indistinguibili (differenza media di 0.12 mesi).

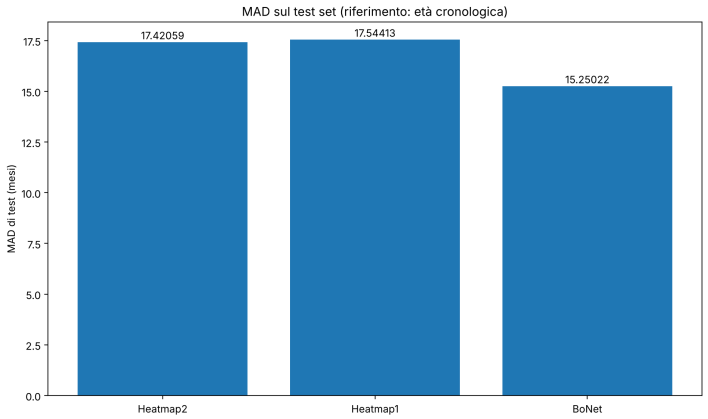


Figura 3.1: MAD sul test set per le tre configurazioni.

3.1.3 Confronto con il paper originale

I valori della Tabella 3.3 non sono direttamente confrontabili con quelli della Tabella 3.1, per tre motivi.

1. **Riferimento.** La MAD di test è calcolata rispetto all'età cronologica; quella del paper rispetto all'età ossea stimata dai radiologi. Nei dati di training e validation la MAD fra le due età è di circa 10 mesi (Sezione 2.2.4).
2. **Inquadratura.** I modelli sono addestrati sulla metà sinistra della radiografia e testati sul ritaglio della mano con la bounding box; nel paper l'inquadratura di training e di test coincide.
3. **Insieme di valutazione.** Il paper usa il test ufficiale tramite il server degli autori; qui la loss di eval è calcolata sul validation set, con l'età ossea come riferimento.

Il confronto più corretto è quindi quello fra la loss di eval (Tabella 3.2) e le righe a immagine intera del paper (Tabella 3.1), che hanno la stessa inquadratura e lo stesso riferimento, anche se su insiemi di dati diversi. Con questo confronto *BoNet* (9.5 mesi) è a circa un mese dal baseline del paper (8.57), mentre il modello con mappa di attenzione (15.4 mesi) è molto lontano dai 7.78 mesi di BoNet.

3.2 Analisi dell'addestramento e delle predizioni

3.2.1 Curve di addestramento

In entrambe le configurazioni la loss di training diminuisce progressivamente lungo le 61 epoche (Figure 3.2 e 3.3). La loss di valutazione diminuisce a sua volta, ma con oscillazioni più marcate e picchi isolati. Questo è compatibile con un normale processo di ottimizzazione; i picchi isolati non bastano da soli a concludere che ci sia *overfitting*, per cui servirebbero più esecuzioni e più split.

3.2.2 Predizioni rispetto all'età reale

La Figura 3.4 mostra, per ciascun paziente del test set, l'età predetta in funzione dell'età reale (cronologica) per le tre configurazioni, insieme alla retta di regressione lineare ai minimi quadrati di ciascuna e alla retta ideale $y = x$. La Tabella 3.4 riporta i parametri dei fit.

Le due configurazioni con mappa di attenzione hanno fit praticamente sovrapposti, con pendenza vicino a 0.68: tendono a sovrastimare le età basse



Figura 3.2: Loss di training e di valutazione per epoca, configurazione con mappa di attenzione.

Tabella 3.4: Fit lineare $\hat{y} = a\,y + b$ delle predizioni sull'età reale e errore medio con segno (predetta meno reale), test set.

Configurazione	Pendenza a	Intercetta b	R^2	Bias medio (mesi)
Heatmap2	0.678	47.37	0.695	+7.75
Heatmap1	0.676	47.73	0.688	+7.80
BoNet	0.814	11.93	0.848	−11.00

e sottostimare quelle alte, cioè a regredire verso la media, e hanno un bias medio positivo. *BoNet* ha una pendenza più vicina a 1 e un R^2 più alto, quindi segue meglio l'andamento della retta ideale, ma è traslato verso il basso (bias medio −11.00 mesi) e sottostima su gran parte dell'intervallo. L'errore dipende anche dal sesso: la MAD di *BoNet* è 18.30 mesi sui maschi e 12.42 sulle femmine, mentre per *Heatmap2* e *Heatmap1* i valori sono rispettivamente 18.34 e 16.57, 18.46 e 16.70.



Figura 3.3: Loss di training e di valutazione per epoca, configurazione *BoNet*.

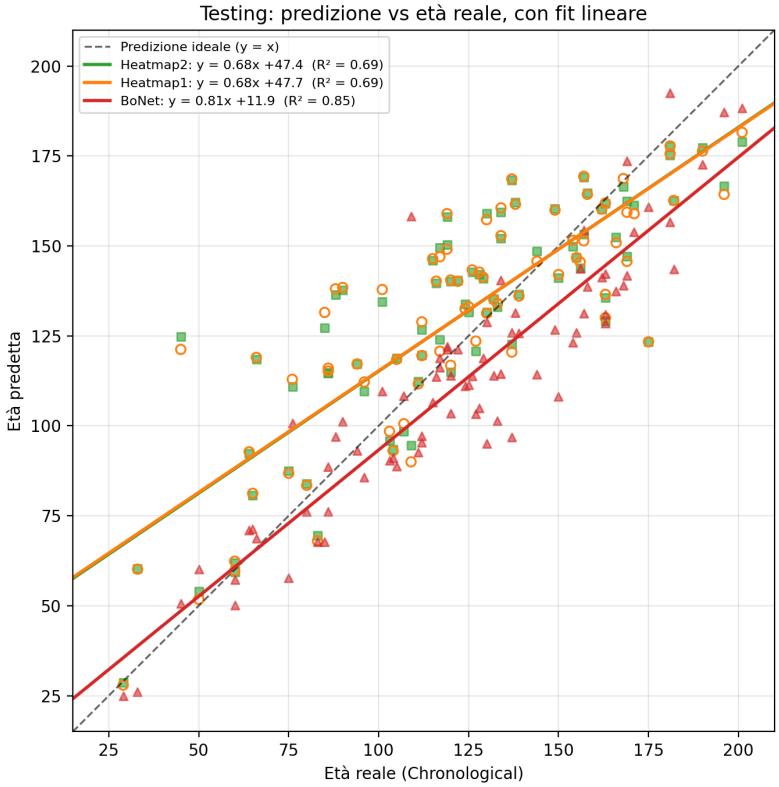


Figura 3.4: Età predetta contro età reale sul test set. Le rette continue sono i fit lineari delle tre configurazioni, la tratteggiata è $y = x$.

Capitolo 4

Conclusione

4.1 Discussione

Replica riuscita? Solo in parte. L'addestramento dei modelli converge, ma il risultato dipende dalla configurazione. Training e validation usano la metà sinistra della radiografia, la condizione «immagine intera» del paper. In questa condizione la configurazione senza punti anatomici, *BoNet*, chiude l'addestramento con una loss di eval di 9.5 mesi (Tabella 3.2), a circa un mese dagli 8.57 del baseline degli autori (Tabella 3.1) [3]. La configurazione con mappa si ferma invece a 15.4 mesi, circa il doppio dei 7.78 riportati per BoNet a immagine intera [3]. La parte che dovrebbe portare il vantaggio, cioè l'uso dei punti anatomici, è quindi quella che non è stata riprodotta.

Ruolo dei punti anatomici. Il paper riporta che l'informazione locale migliora la stima: BoNet è sempre migliore del baseline, di circa mezzo mese (7.78 contro 8.57 a immagine intera, 7.60 contro 8.05 con ritaglio) [3]. In questa replica il vantaggio non compare, ed è anzi il contrario. Tutte le misure disponibili vanno nella stessa direzione: rispetto alla configurazione con mappa di attenzione, *BoNet* ha la loss di training più bassa (8.5 contro 15.7), la loss di eval più bassa (9.5 contro 15.4, Tabella 3.2) e la MAD di test più bassa (15.25 contro 17.42 e 17.54, Tabella 3.3). Sul test la differenza non è statisticamente netta, perché gli intervalli di confidenza si sovrappongono; nelle loss per epoca il divario è invece ampio.

Il divario nella loss di eval, di circa 6 mesi, è molto maggiore del vantaggio di mezzo mese del paper. Questo non permette di concludere che la mappa non sia utile, e indica piuttosto un errore nell'implementazione o nell'addestramento. Poiché anche la loss di *training* resta alta per la configurazione con mappa, la causa più probabile è nell'ottimizzazione o nel modo in cui la mappa è integrata nella rete, e non in un eccesso di adattamento.

Possibili cause del mancato vantaggio. Le seguenti ipotesi non sono state verificate.

- **Durata dell'addestramento.** In entrambe le configurazioni la loss di training è ancora in discesa all'ultima epoca (circa 1.1 mesi nelle ultime 10 epoche); 60 epoche potrebbero non bastare, in particolare per il percorso aggiuntivo.
- **Pesi del baseline di partenza.** Sono stati addestrati qui da pesi casuali, per 60 epoche con *learning rate* 10^{-4}, invece di 150 epoche con 3×10^{-3}.
- **Convoluzione 1×1 di fusione.** Non esiste nel baseline e parte da pesi casuali, per cui il corpo di Inception-V3 inizializzato dal baseline riceve all'inizio feature molto diverse da quelle su cui era stato addestrato.
- **Scala della mappa.** In questo lavoro il massimo di ogni mappa è portato a 255, diversamente dal codice ufficiale, dove l'ampiezza è inferiore a 1 e non viene riscalata.
- **Codice condiviso diverso da quello usato nel paper.** Il codice del repository [1] potrebbe non coincidere con quello con cui sono stati ottenuti i risultati del paper [3]. Alcuni indizi: la condizione di salvataggio del checkpoint contiene una disuguaglianza errata, per cui il modello salvato è quello con l'errore di validazione più grande invece che quello con l'errore più piccolo (Sezione 2.5); lo scheduler usa un fattore 0.8, mentre il testo del paper indica 0.1; e il dataset distribuito non contiene alcune immagini che il paper dichiara, cioè 1 in training, 3 in validation e 1 in test (Sezione 2.2). Non è quindi garantito che il protocollo descritto nel paper sia riproducibile con il materiale pubblico.
- **Rimozione di Horovod.** Rispetto a un setup multi-GPU cambiano la *batch size* effettiva e la scala del *learning rate*.
- **Una sola esecuzione.** Ciascuna configurazione è stata addestrata una volta, per cui non si conosce la variabilità fra esecuzioni.

Errori delle rette di regressione. Il diverso comportamento delle rette di regressione (Tabella 3.4) mostra errori di natura diversa: bias negativo per *BoNet* e regressione verso la media, con bias positivo, per le configurazioni con mappa di attenzione.

Training e test su inquadrature diverse. Ogni radiografia di RHPE contiene due mani, quindi bisogna selezionare quella sinistra. Il paper definisce la condizione «immagine intera» per RHPE come la metà sinistra della

radiografia, che include solo la mano non dominante, e in alternativa usa il ritaglio con la bounding box della mano [3]. In questo lavoro training e validation sono stati eseguiti sulla metà sinistra, perché il comando di addestramento non passava l'opzione `--cropped`, mentre il test è stato eseguito con `--cropped`, cioè sul ritaglio della bounding box.

Le due inquadrature sono diverse. Nella metà sinistra la mano occupa una parte dell'immagine ed è circondata da sfondo; nel ritaglio la mano riempie l'inquadratura, per cui appare più grande, e il rettangolo ha un rapporto d'aspetto diverso. Entrambe sono poi portate a 500×500 pixel senza preservare il rapporto d'aspetto, quindi la mano è deformata in modo diverso nei due casi. Il modello è così testato su immagini con scala e deformazione diverse da quelle viste in addestramento; l'*augmentation* con scala fra 1 e 1.2 compensa solo in parte. Il paper ottiene i suoi migliori risultati addestrando e testando sui ritagli [3].

Questa differenza non è però la causa dello scarto dal paper: un addestramento ripetuto con `--cropped`, in cui training, validation e test usano la stessa inquadratura, ha dato risultati ancora peggiori. L'inquadratura resta quindi una differenza di protocollo rispetto alla condizione «immagine intera» del paper, ma non spiega il mancato vantaggio della mappa. Un secondo motivo per cui le MAD di test non vanno lette come quelle del paper è il riferimento: il test usa l'età cronologica, mentre il paper usa l'età ossea.

Punti annotati contro punti stimati. *Heatmap1* e *Heatmap2* ottengono MAD di test praticamente identiche (17.54 e 17.42, differenza appaiata +0.12 mesi con IC che include lo zero). Poiché tra le due configurazioni cambiano solo le coordinate dei punti, mentre modello e ritaglio restano gli stessi, il risultato ha due letture. La prima è che i punti stimati dalla pipeline automatica [4] (mAP@[.5:.95] di 0.7668 sul test) siano sufficienti per costruire la mappa, senza un peggioramento misurabile rispetto ai punti annotati. La seconda è che il modello usi poco la mappa e darebbe quindi risultati simili con qualunque insieme di punti. Un test con la mappa azzerata o spostata permetterebbe di distinguere le due letture.

4.2 Limiti e sviluppi futuri

Limiti.

- **Riferimento del test.** Le metriche di test sono calcolate sull'età cronologica e non sull'età ossea, per cui non sono confrontabili con la MAD del paper (Capitolo 3).

- **Inquadratura.** Training e validation usano la metà sinistra della radiografia e il test il ritaglio della mano; il paper addestra e testa sulla stessa inquadratura. Un addestramento con `--cropped`, che uniforma le inquadrature, ha dato risultati ancora peggiori.
- **Dimensione del test.** Con 79 pazienti gli intervalli di confidenza sono ampi (circa ±3 mesi) e le differenze fra configurazioni non sono distinguibili dalla variabilità campionaria.
- **Una sola esecuzione.** Gli addestramenti non sono stati ripetuti con inizializzazioni diverse, quindi non si può stimare la variabilità fra esecuzioni.
- **Selezione del checkpoint.** Il test usa i pesi dell'ultima epoca e non quelli con la minima loss di eval (epoca 59 per le configurazioni con mappa, epoca 50 per *BoNet*); la loss di eval dell'ultima epoca supera quel minimo di circa 0.65 mesi in entrambi i casi (Tabella 3.2).
- **Codice e dati pubblici.** Il codice e il dataset condivisi presentano errori e mancanze (checkpoint salvato con una disuguaglianza errata, immagini assenti) e potrebbero non coincidere con quelli usati nel paper; questo limita la possibilità di una replica fedele.
- **Differenze di protocollo.** Il numero di epoche (60 contro 50), l'esecuzione su una sola GPU NVIDIA 3060, senza Horovod e i pesi del baseline di partenza, addestrati qui con 60 epoche e *learning rate* 10^{-4} invece di 150 epoche e 3×10^{-3}, differiscono da quelli del paper [3]; non è possibile isolare il contributo di ciascuna differenza.
- **Una sola coorte.** Tutti i risultati riguardano RHPE, raccolto da un singolo centro; la generalizzazione ad altre popolazioni, come per BoneXpert [18], non è verificata.

Sviluppi futuri.

- Valutare la rete con mappa azzerata o spostata, per misurare quanto la usa.
- Ottenere la MAD sul test ufficiale di RHPE tramite il server di valutazione degli autori [3], così da confrontarsi direttamente con il paper.
- Verificare l'integrazione della mappa di attenzione (normalizzazione, pesi del baseline di partenza, durata dell'addestramento), tra le cause possibili del mancato vantaggio rispetto a *BoNet*.

- Ripetere gli addestramenti con più inizializzazioni, scegliendo il checkpoint sul solo validation set, per quantificare la variabilità.
- Analizzare in modo sistematico il bias di *BoNet* e la regressione verso la media delle configurazioni con mappa di attenzione, anche per sesso.
- Studiare l'effetto dei parametri della mappa di attenzione (ampiezza delle gaussiane) e provare punti anatomici ottenuti con altri modelli, ad esempio Simple Baselines [19].

Ringraziamenti

Desidero ringraziare il professor Marco Grangetto, relatore di questa tesi, per la disponibilità e per le indicazioni che hanno guidato il mio lavoro.

Un ringraziamento particolare va a Michele Cannito, correlatore, per il tempo dedicato alla revisione del testo e per i suggerimenti puntuali, che hanno contribuito a migliorare questo elaborato.

Ringrazio infine Daniele Giacomelli per la collaborazione: i primi due stadi della pipeline, da lui sviluppati, sono alla base del lavoro svolto in questa tesi.

Bibliografia

[1] BCV-Uniandes. BoNet: codice ufficiale del terzo stadio (bone age assessment). `https://github.com/BCV-Uniandes/Bonet`. Repository GitHub associato a [3].

[2] Mark Cicero and Alexander Bilbily. Machine learning and the future of radiology: How we won the 2017 RSNA ML challenge, 2017. Resoconto della soluzione vincitrice della RSNA Pediatric Bone Age Challenge.

[3] María Escobar, Cristina González, Felipe Torres, Laura Daza, Gustavo Triana, and Pablo Arbeláez. Hand pose estimation for pediatric bone age assessment. In *Medical Image Computing and Computer Assisted Intervention – MICCAI 2019*, volume 11769 of *Lecture Notes in Computer Science*, pages 531–539. Springer, 2019.

[4] Daniele Giacomelli. Hand pose estimation per la stima dell'età ossea pediatrica. Tesi di laurea, Università degli Studi di Torino, Corso di Laurea Triennale in Informatica, 2026. Relatore: M. Grangetto; correlatore: M. Cannito. A.A. 2025/2026.

[5] Ian Goodfellow, Yoshua Bengio, and Aaron Courville. *Deep Learning*. MIT Press, 2016.

[6] William W. Greulich, S. Idell Pyle, and T. Wingate Todd. *Radiographic Atlas of Skeletal Development of the Hand and Wrist*. Stanford University Press, Palo Alto, 2 edition, 1959.

[7] Safwan S. Halabi, Luciano M. Prevedello, et al. The RSNA pediatric bone age machine learning challenge. *Radiology*, 290(2):498–503, 2019.

[8] Curtis Hardyck and Lewis F. Petrinovich. Left-handedness. *Psychological Bulletin*, 84(3):385, 1977.

[9] Kaiming He, Georgia Gkioxari, Piotr Dollár, and Ross Girshick. Mask R-CNN. In *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, 2017.

[10] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 770–778, 2016.

[11] Vladimir I. Iglovikov, Alexander Rakhlin, Alexandr A. Kalinin, and Alexey A. Shvets. Paediatric bone age assessment using deep convolutional neural networks. In *Deep Learning in Medical Image Analysis and Multimodal Learning for Clinical Decision Support (DLMIA/ML-CDS 2018)*, volume 11045 of *Lecture Notes in Computer Science*, pages 300–308. Springer, 2018.

[12] Diederik P. Kingma and Jimmy Ba. Adam: A method for stochastic optimization. In *International Conference on Learning Representations (ICLR)*, 2015.

[13] Tsung-Yi Lin, Michael Maire, Serge Belongie, James Hays, Pietro Perona, Deva Ramanan, Piotr Dollár, and C. Lawrence Zitnick. Microsoft COCO: Common objects in context. In *Computer Vision – ECCV 2014*, volume 8693 of *Lecture Notes in Computer Science*, pages 740–755. Springer, 2014.

[14] Shaoqing Ren, Kaiming He, Ross Girshick, and Jian Sun. Faster R-CNN: Towards real-time object detection with region proposal networks. In *Advances in Neural Information Processing Systems (NIPS)*, pages 91–99, 2015.

[15] David E. Rumelhart, Geoffrey E. Hinton, and Ronald J. Williams. Learning representations by back-propagating errors. *Nature*, 323(6088):533–536, 1986.

[16] Christian Szegedy, Vincent Vanhoucke, Sergey Ioffe, Jonathon Shlens, and Zbigniew Wojna. Rethinking the inception architecture for computer vision. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 2818–2826, 2016.

[17] J. M. Tanner, R. H. Whitehouse, W. A. Marshall, and B. S. Carter. Prediction of adult height from height, bone age, and occurrence of menarche, at ages 4 to 16 with allowance for midparent height. *Archives of Disease in Childhood*, 50(1):14–26, 1975.

[18] Hans Henrik Thodberg, Sven Kreiborg, Anders Juul, and Karen Damgaard Pedersen. The BoneXpert method for automated determination of skeletal maturity. *IEEE Transactions on Medical Imaging*, 28(1):52–66, 2009.

[19] Bin Xiao, Haiping Wu, and Yichen Wei. Simple baselines for human pose estimation and tracking. In *Computer Vision – ECCV 2018*, volume 11210 of *Lecture Notes in Computer Science*, pages 472–487. Springer, 2018.